

Giới thiệu đề tài

Môn học: Dữ liệu lớn (CO5135)

"Hệ thống Gợi ý Phim Quy mô lớn với Spark MLlib ALS & Đánh giá Hiệu năng Phân tán trên MovieLens 32M"

GVHD: GS. TS. Thoại Nam – TS. Lê Thanh Vân

Sinh viên thực hiện:

Nguyễn Thanh Lộc	*2311958*
Nguyễn Đinh Nhật Quang	*2470068*
Nguyễn Văn Tâm	*2570358*

1. Chủ đề Đề tài

1. Topic
2. Data Source
3. Problems

Chủ đề (Topic 14 – Recommender Systems & HPC Benchmark)

Hệ thống Gợi ý Phim Quy mô lớn với Spark MLlib ALS & Đánh giá Hiệu năng Phân tán trên MovieLens 32M

- **Bối cảnh**: Nhu cầu cá nhân hóa gợi ý trên hàng chục triệu tương tác vượt quá khả năng xử lý bộ nhớ của các công cụ máy đơn truyền thống.
- **Mục tiêu trọng tâm**:
  - **Big Data ETL**: Tiền xử lý và lưu trữ phân tán 32M bản ghi với **PySpark** & **Apache Parquet**.
  - **Recommender System**: Huấn luyện mô hình lọc cộng tác **Spark MLlib ALS** sinh gợi ý **Top-N** và xử lý *Cold-start*.
  - **HPC & Quality Benchmark**: Đánh giá độ chính xác (**RMSE, NDCG@K**) và khả năng mở rộng tính toán (**Data Scaling, Speedup – Định luật Amdahl**).
- **Pipeline tổng quan**: `MovieLens 32M` → `Parquet Lake` → `Spark ALS (Top-N)` → `HPC Benchmark`

2. Nguồn dữ liệu: MovieLens 32M

1. Topic
2. Data Source
3. Problems

Nguồn thu thập: Tập dữ liệu chuẩn **MovieLens 32M** từ **GroupLens Research** – University of Minnesota (grouplens.org/datasets/movielens/32m).

Tập tin	Số lượng bản ghi	Cấu trúc trường dữ liệu chính
`ratings.csv`	**32.000.204** ratings	`userId`, `movieId`, `rating` (0.5 → 5.0), `timestamp`
`movies.csv`	**87.585** bộ phim	`movieId`, `title` (kèm năm), `genres` (20 thể loại)
`tags.csv`	**2.000.072** nhãn	`userId`, `movieId`, `tag`, `timestamp`
`links.csv`	**87.585** liên kết	`movieId`, `imdbId`, `tmdbId`

Đặc trưng Dữ liệu lớn:

- **Quy mô**: **200.948** người dùng ($\geq$ 20 ratings/user), dung lượng thô $\sim$ 1.0 GB CSV; kích thước ma trận tương tác $200.948 \times 87.585 \approx$ **17.6** tỷ ô.
- **Độ thưa cao**: Hơn **99.82%** ma trận User–Item bị khuyết giá trị, đòi hỏi giải thuật phân rã ma trận phân tán.
- **Phân bố đuôi dài**: Lượt đánh giá tập trung mạnh ở nhóm phim phổ biến, đa số phim thuộc vùng đuôi dài ít tương tác.

3. Bài toán & Hướng giải quyết

1. Topic
2. Data Source
3. Problems

1. **Bài toán 1 – Lưu trữ & Tiền xử lý Phân tán**:
   - *Thách thức*: Công cụ đơn luồng (Pandas/Scikit-learn) gây tràn RAM (*OOM*) và nghẽn I/O trên 32M dòng.
   - *Giải pháp*: Pipeline **PySpark DataFrame**, lưu **Parquet** phân hoạch theo năm, bật *KryoSerializer* & *AQE*.
2. **Bài toán 2 – Lọc cộng tác Ma trận Thưa & Cold-start**:
   - *Thách thức*: Đồ thị RDD (*DAG Lineage*) của ALS sâu dễ gây `StackOverflowError`; user mới chưa có lịch sử.
   - *Giải pháp*: Huấn luyện **Spark ALS** kèm *Checkpointing*; lọc phim đã xem (`left_anti`); **Bayesian Popularity**.
3. **Bài toán 3 – Đánh giá Chất lượng & Hiệu năng**:
   - *Chất lượng gợi ý*: Đo lường **RMSE**, **Precision@**K, **NDCG@**K trên tập kiểm thử.
   - *Hiệu năng HPC*: Khảo sát *Data Scaling* (5% $\rightarrow$ 100%) và kiểm chứng **Định luật Amdahl** qua **Speedup** ($S_p = T_1/T_p$), **Efficiency** ($E_p = S_p/p$) khi thay đổi số nhân xử lý (Cores).